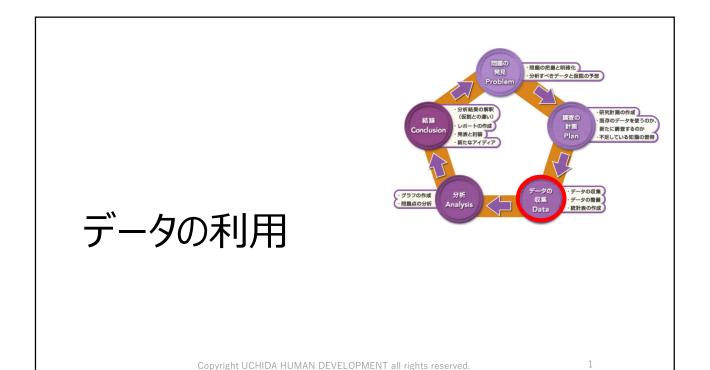
数理・データサイエンス・AI入門

第7回 データサイエンス実践(2)

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

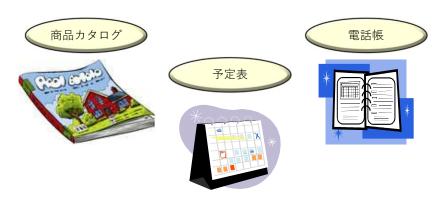
0



データベースとは?

□ データベースとは、「データ(情報)」の「ベース(基地)」のこと

• データを1カ所に集め、様々な用途に活用できるようにしたものを「データベース」と呼びます



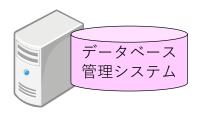
Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

.

2

データベース管理システムとは?

- □ データベース管理システムとは
 - DataBase Management System: DBMS
 - データを一元管理する
 - データを加工して、合計や平均などを求めることも可能
- □ データベース管理システムを使うと、Excelのような表計算ソフトでも扱いきれないような何億件という情報を、高速に処理することが可能

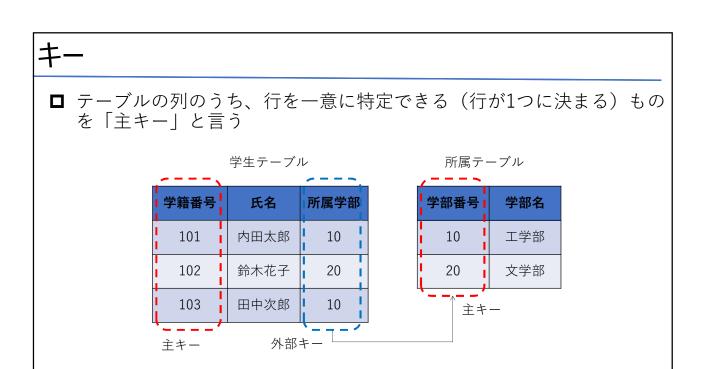


Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

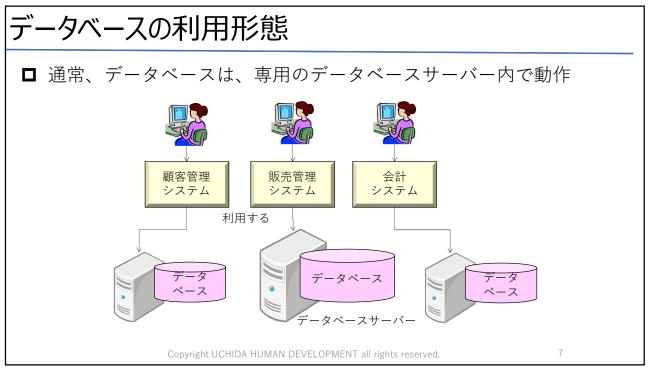
主なデータベース製品 有償 ベンダー 製品名 Oracle Database Oracle SQL Server Microsoft DB2 IBM Access Microsoft 無償 製品名 ベンダー MySQL Oracle PostgreSQL PostgreSQL.org Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

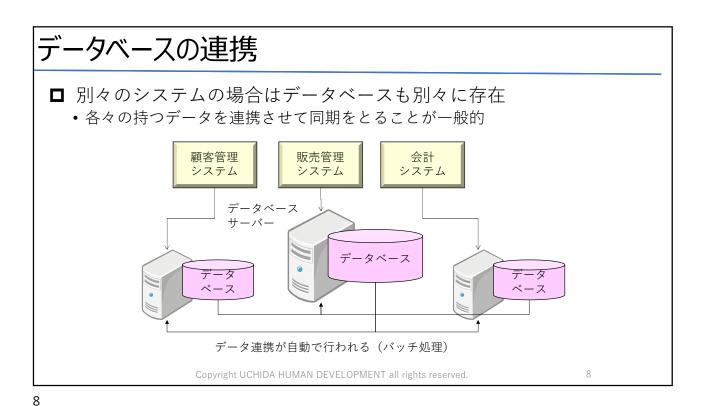
4

行と列 ロ リレーショナル型データベース(RDB) ・「テーブル」という表の形式でデータを保存 ・行と列が交わった1つ1つのセルのことを「フィールド」 ・フィールドには、1つの値しか格納することは出来ません **番号**「大名 「所属 101 内田太郎 営業部 102 鈴木花子 管理部 Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.



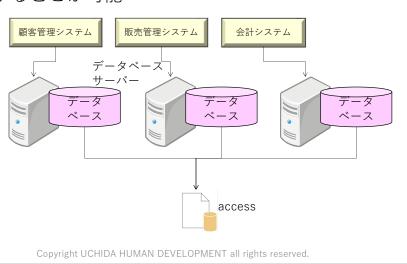
Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.





データの利用方法②

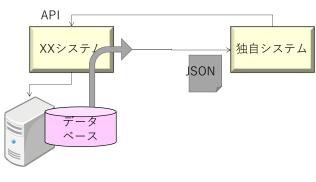
■ Accessを使うと複数のデータベースのデータを自動的に1か所にまとめて利用することが可能



10

データの利用方法③

- API (Application Programming Interface) を経由してデータをやりとりすることも可能
 - データ分析を行う際などにプログラムを書いて実現します



Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

11

JSONデータ

- □ 以下のような形式でデータを入手することができる
 - プログラムで自動処理しやすい形式になっています
 - 基本形式 { "項目名①":データ, "項目名②":データ }
 - 例 { "学籍番号":101, "氏名":"内田太郎", "所属":"工学部" }

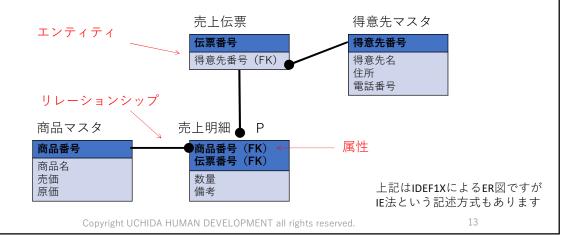
Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

12

12

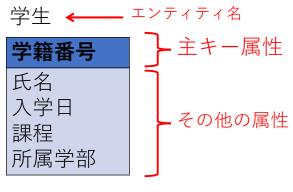
ER図とは

- ER図 (Entity Relationship Diagram)
 - 対象業務の分析を行い、モデル化した結果を表現するもの



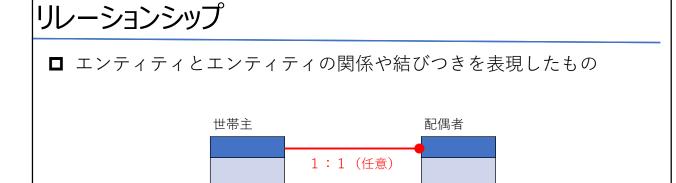
エンティティ

- □ システムで「管理対象」としてとらえたいもの
 - 最終的には、テーブルとほぼ同じ単位になることが多い
 - ER図のインスタンスは行/レコードに相当、属性は列に相当



 $\label{thm:copyright} \mbox{Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.}$

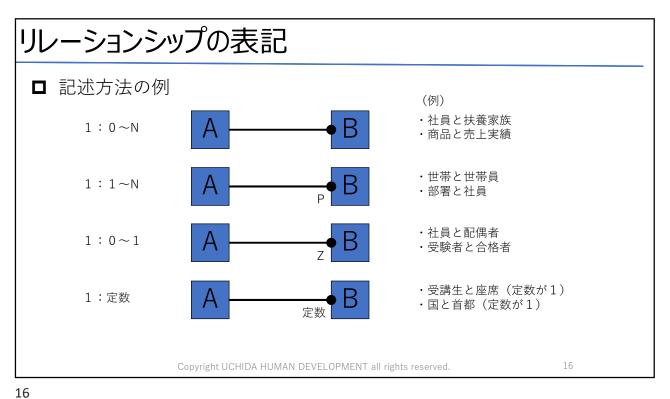
14

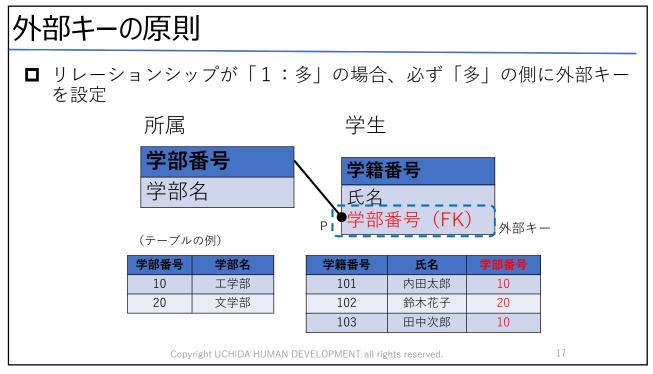


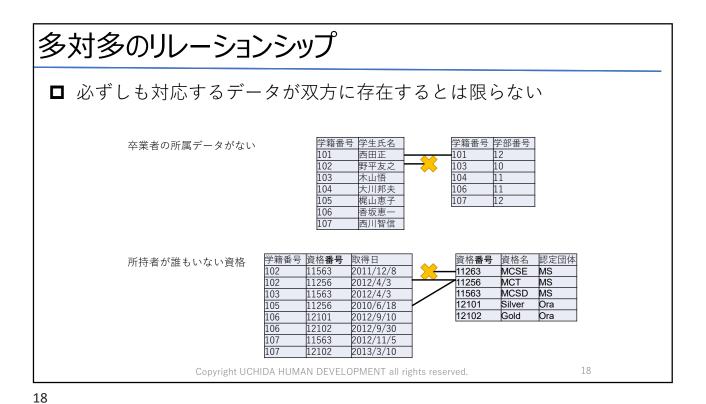


Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

15







多対多のリレーションシップ □ テーブルの結合手法は集合の概念で捉えることができる 学籍番号 学生氏名 学籍番号 学部番号 西田正 101 102 野平友之 103 10 103 木山悟 104 104 大川邦夫 106 11 積集合 和集合 梶山恵子 105 107 香坂恵-106 108 10 西川智信 学籍番号 101 学籍番号 101 学生氏名 西田正 西田正 103 104 木山悟 10 野平友之 103 木山悟 106 香坂恵-104 大川邦夫 11 西川智信 106 香坂恵 107 西川智信 Copyright UCHIDA HUMAN DEVELOPMENT al 108 19

【演習】

□ 次の2つのテーブルを結合したとき、どのようなアウトプットになる か考えてみましょう

※まずは和集合の考え方でやってみてください (時間があれば積集合も)

学籍番号	学生氏名
101	西田正
102	野平友之
103	木山悟
104	大川邦夫
105	梶山恵子
106	香坂恵一
107	西川智信

学籍番号	資格番号	取得日
102	11563	2011/12/8
102	11256	2012/4/3
103	11563	2012/4/3
105	11256	2010/6/18
106	12101	2012/9/10
106	12102	2012/9/30
107	11563	2012/11/5
107	12102	2013/3/10



Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

20

20

正規化とは

□ 正規化の作業をすすめていくことでデータ構造がわかりやすく単純に

学籍番号	氏名	学部番号	学部名
101	内田太郎	10	工学部
102	鈴木花子	20	文学部
103	田中次郎	10	工学部

正規化

学籍番号	氏名	学部番号
101	内田太郎	10
102	鈴木花子	20
103	田中次郎	10

学部番号	学部名
10	工学部
20	文学部

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

正規化していない表の問題点

- 更新忘れによって矛盾が生じる
 - 例えば、工学部の学部所在地が「○○号館1F」に更新された場合、表中の複数レコードを更新しなければなりません

学生取得資格

学籍番号	学生氏名	学部番号	学部名	学部所在地	資格 番号	資格名	認定団体	取得日
1.01		1.0	- 224 A12	OO B #25	11263	MCSE	MS	2010/1/5
101	西田正	12	工学部 〇〇号館3F 1	11256	MCT	MS	2011/8/10	
102	野平友之	12	工学部 (○○号館3FF	11563	MCSD	MS	2011/12/8	
102	サーズに	12		11256	MCT	MS	2012/4/3	
103	木山悟	10	文学部	○○号館5F	11563	MCSD	MS	2012/4/3
104	大川邦夫	11	商学部	○○号館2F	11263	MCSE	MS	2010/6/18
105	梶山恵子	10	文学部	○○号館5F	11256	MCT	MS	2010/6/18
106	香坂恵一	C# 11	商学部		12101	Silver	Ora	2012/9/10
106	督	11	尚子副	○○号館2F	12102	Gold	Ora	2012/9/30
107	107 西川智信 12 工学音	十学如	O O D ##05	11563	MCSD	MS	2012/11/5	
107	四川百店	12	工于即	□ 「学部 ○○号館3F	12102	Gold	Ora	2013/3/10

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

2

22

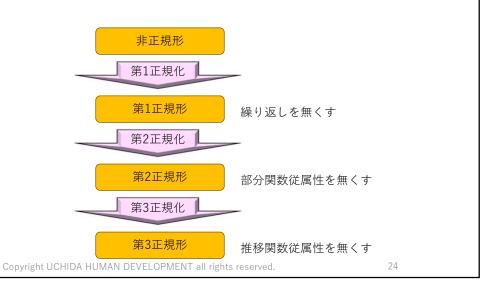
正規化のメリット

- □ データの冗長性を排除できる
 - 一同一種類のデータが分散格納されません。従って、処理対象データを特定しやすくなり更新 時異常を抑制できます また、必要な格納メディア容量も小さくなります
- □ データ構造が分かりやすくなる
 - 一正規化をすすめていくと、格納されるデータは2次元の表であらわすことができるようになり、 構造を把握しやすいテーブルになります

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

第1~第3正規化

□ 正規化は段階に分けて実施



24



□ 非正規形の表には主キーに対して繰り返しが存在

学生取得資格

, <u> </u>	חואלוו									
学籍番号	学生氏名	学部番号	学部名	学部所在地	資格 番号	資格名	認定団体	取得日	_	
101		10	工学部	○○号館3F	11263	MCSE	MS	2010/1/5	操り返し	
101	西田正	12	工字部	○○	11256	MCT	MS	2011/8/10	一」様り返し	
102	野平友之	12	工学部	○○号館3F	11563	MCSD	MS	2011/12/8	7	
102	對十及足	12	ㅗᅮᇚ	工字部	3 〇〇号貼3F	11256	MCT	MS	2012/4/3	<u></u>
103	木山悟	10	文学部	○○号館5F	11563	MCSD	MS	2012/4/3		
104	大川邦夫	11	商学部	○○号館2F	11263	MCSE	MS	2010/6/18		
105	梶山恵子	10	文学部	○○号館5F	11256	MCT	MS	2010/6/18		
106	香坂恵一	11	商学部	○○号館2F	12101	Silver	Ora	2012/9/10	Ţ	
100	省级忠一	11	尚子副	〇〇亏貼2下	12102	Gold	Ora	2012/9/30		
107	西川智信	12	工学部	○○号館3F	11563	MCSD	MS	2012/11/5	٦	
107	四川百洁	12	工 于 即	OO 5階3F	12102	Gold	Ora	2013/3/10	<u> </u>	

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

第1正規形

□ 非正規形の表から、繰り返し部分を分離したものが第1正規形

学生

学籍番号	学生氏名	学部番号	学部名	学部所在地
101	西田正	12	工学部	○○号館3F
102	野平友之	12	工学部	○○号館3F
103	木山悟	10	文学部	○○号館5F
104	大川邦夫	11	商学部	○○号館2F
105	梶山恵子	10	文学部	○○号館5F
106	香坂恵一	11	商学部	○○号館2F
107	西川智信	12	工学部	○○号館3F

資格取得

学籍番号	資格 番号	資格名	認定団体	取得日
101	11263	MCSE	MS	2010/1/5
101	11256	MCT	MS	2011/8/10
102	11563	MCSD	MS	2011/12/8
102	11256	MCT	MS	2012/4/3
103	11563	MCSD	MS	2012/4/3
104	11263	MCSE	MS	2010/6/18
105	11256	MCT	MS	2010/6/18
106	12101	Silver	Ora	2012/9/10
106	12102	Gold	Ora	2012/9/30
107	11563	MCSD	MS	2012/11/5
107	12102	Gold	Ora	2013/3/10

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

26

26

第1正規形

- □ 資格取得テーブルに注目
 - 資格番号が決まれば、資格名と認定団体は決まります

学生

学籍番号	学生氏名	学部番号	学部名	学部所在地
101	西田正	12	工学部	○○号館3F
102	野平友之	12	工学部	○○号館3F
103	木山悟	10	文学部	○○号館5F
104	大川邦夫	11	商学部	○○号館2F
105	梶山恵子	10	文学部	○○号館5F
106	香坂恵一	11	商学部	○○号館2F
107	西川智信	12	工学部	○○号館3F

資格取得

学籍番号	資格 番号	資格名	認定団体	取得日
101	11263	MCSE	MS	2010/1/5
101	11256	MCT	MS	2011/8/10
102	11563	MCSD	MS	2011/12/8
102	11256	MCT	MS	2012/4/3
103	11563	MCSD	MS	2012/4/3
104	11263	MCSE	MS	2010/6/18
105	11256	MCT	MS	2010/6/18
106	12101	Silver	Ora	2012/9/10
106	12102	Gold	Ora	2012/9/30
107	11563	MCSD	MS	2012/11/5
107	12102	Gold	Ora	2013/3/10

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

第2正規形

□ 主キーの一部のみに従属する属性を分離したものが、第2正規形

学生

 学籍番号
 学生氏名
 学部番号
 学部名
 学部所在地

 101
 西田正
 12
 工学部
 ○○号館3F

 102
 野平友之
 12
 工学部
 ○○号館3F

 103
 木山悟
 10
 文学部
 ○○号館5F

 104
 大川邦夫
 11
 商学部
 ○○号館2F

 105
 梶山恵子
 10
 文学部
 ○○号館2F

 106
 香坂恵一
 11
 商学部
 ○○号館3F

 107
 西川智信
 12
 工学部
 ○○号館3F

資格取得

学籍番号	資格 番号	取得日
101	11263	2010/1/5
101	11256	2011/8/10
102	11563	2011/12/8
102	11256	2012/4/3
103	11563	2012/4/3
104	11263	2010/6/18
105	11256	2010/6/18
106	12101	2012/9/10
106	12102	2012/9/30
107	11563	2012/11/5
107	12102	2013/3/10

資格

資格 番号	資格名	認定団体
11263	MCSE	MS
11256	MCT	MS
11563	MCSD	MS
12101	Silver	Ora
12102	Gold	Ora

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

28

28

第2正規形

■ 学生テーブルに注目

学生

学籍番号	学生氏名	学部番号	学部名	学部所在地
101	西田正	12	工学部	○○号館3F
102	野平友之	12	工学部	○○号館3F
103	木山悟	10	文学部	○○号館5F
104	大川邦夫	11	商学部	○○号館2F
105	梶山恵子	10	文学部	○○号館5F
106	香坂恵一	11	商学部	○○号館2F
107	西川智信	12	工学部	○○号館3F

資格取得

学籍番号	資格 番号	取得日
101	11263	2010/1/5
101	11256	2011/8/10
102	11563	2011/12/8
102	11256	2012/4/3
103	11563	2012/4/3
104	11263	2010/6/18
105	11256	2010/6/18
106	12101	2012/9/10
106	12102	2012/9/30
107	11563	2012/11/5
107	12102	2013/3/10

資格

資格 番号	資格名	認定団体
11263	MCSE	MS
11256	MCT	MS
11563	MCSD	MS
12101	Silver	Ora
12102	Gold	Ora

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

第3正規形

■ 第2正規形の表から「A→B→C」というような従属性を無くしたもの

学生

学籍番号	学生氏名	学部番号
101	西田正	12
102	野平友之	12
103	木山悟	10
104	大川邦夫	11
105	梶山恵子	10
106	香坂恵一	11
107	西川智信	12

所属

学部番号	学部名	学部所在地
10	文学部	○○号館5F
11	商学部	○○号館2F
12	工学部	○○号館3F

資格取得

兴然亚口	*************************************	D=/8 D
学籍番号	負俗留写	取得日
101	11263	2010/1/5
101	11256	2011/8/10
102	11563	2011/12/8
102	11256	2012/4/3
103	11563	2012/4/3
104	11263	2010/6/18
105	11256	2010/6/18
106	12101	2012/9/10
106	12102	2012/9/30
107	11563	2012/11/5
107	12102	2013/3/10

資格

資格 番号	資格名	認定団体
11263	MCSE	MS
11256	MCT	MS
11563	MCSD	MS
12101	Silver	Ora
12102	Gold	Ora

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

30

30

分析のためのデータ加工

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

データの種類と特徴

- □ データは「量的データ」と「質的データ」がある
 - 分析するにあたっては自身が取り扱うデータの特性を把握しておきます



32

データ加工のバリエーション

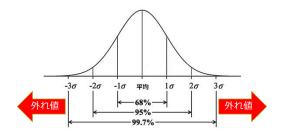
- □ データクレンジング
 - データは入手したものがそのまま分析にかけられる状態にあることはほぼありません

項目	不具合の内容
エラー値	・データの入力ミス、システムの制約をすり抜 けたものなど
欠損値	・データが入っていない
外れ値	・データ集団から著しく外れた値
型違い	・数字データに文字列が入っている
文字化け	・OSが異なる場合に発生する(Win-Mac)
カンマ	・CSVファイルで、金額が1,000,000など

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

外れ値の処理方法

- 標準偏差を基準に判断します
- \Box 外れ値のデータは 3 σ の値にそろえるか、該当データ自体を除外します



Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

34

34

データクレンジングの例

- □ データベースから抽出したデータの典型的な加工パターン
 - 数値データでないものは、数値に変換
 - 欠損があるものはデータを補うか、行ごと削除
 - 分析に関係のない列は削除
 - ✔ 購買額
 - ✓ 生年月日
 - ✔ 興味分野
 - ✓ 顧客コード
 - ✔ サービス満足度
 - ✓ 性別
 - ✔ 職業
 - ✓ 婚姻
 - ✔ 給与水準
 - ✔ 家族の数
 - ✓ 勤務先
 - ▼ 勤続年数
 - ・ 弱帆中級✓ 現住所に住んでいる年数

数値データでないもの

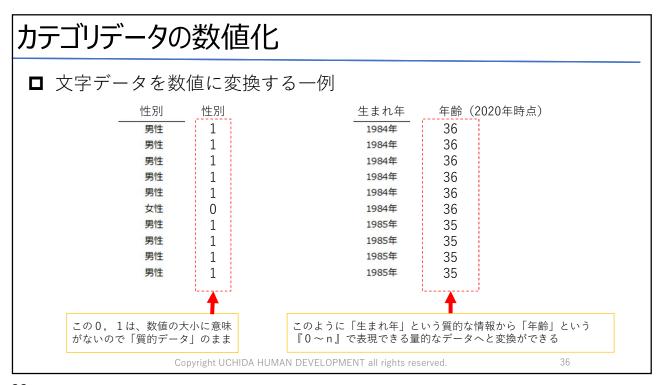
「生年月日」→期間の年数を計算=年齢 「性別」→男性を"1"、女性を"0" etc

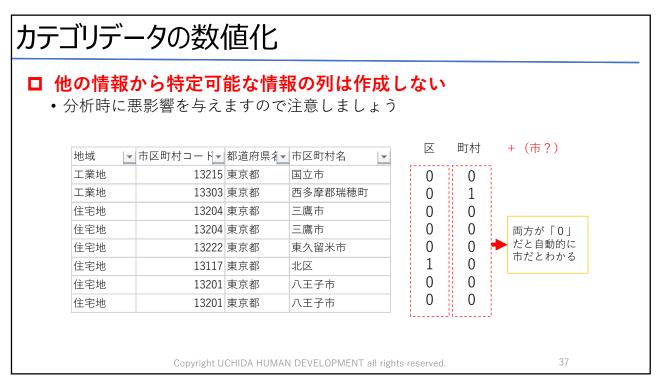
欠損

- ✔ 複数システムの統合による欠損
- ✓ アンケート未回答者のデータ欠損 etc

Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

3 F





仮説をもとにした意味付け

- □ 変換方法は1通りではなく複数考える
 - 複数の仮説が立つ場合、どの切り口が調べたい事象と関係しているのかを複数同時に調べることができます

地域	▼市区町村コード▼都道	道府県名 市区町村名
工業地	13215 東京	京都国立市
工業地	13303 東京	京都 西多摩郡瑞穂町
住宅地	13204 東京	京都三鷹市
住宅地	13204 東京	京都三鷹市
住宅地	13222 東京	京都東久留米市
住宅地	13117 東京	京都 北区
住宅地	13201 東京	京都 八王子市
住宅地	13201 東京	京都 八王子市

X	町村	中央線沿線	人口10万人以上
0	0	1	0
0	1	0	0
0	0	1	1
0	0	1	1
0	0	0	1
1	0	0	1
0	0	1	1
0	0	1	1
نححجما	التناسيا	التتتتينا	التتتتيا

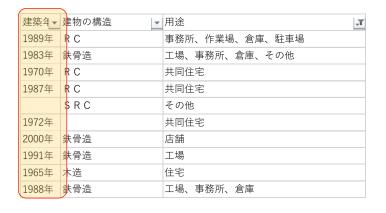
Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

38

38

仮説をもとにした意味付け

- □ 課題設定時の仮説をもとにグループ分けする。
 - 分析結果の考察で最初の仮説が違った場合は、別の仮説を立ててグループ分けを変えるなどして分析を試行錯誤する。

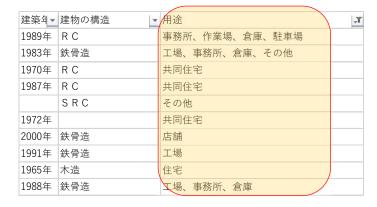


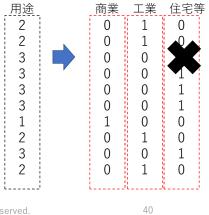


Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

仮説をもとにした意味付け

■ 1つのカラムで分類を作成したものをそれぞれ別の要因として分析を 行う際にはカラムを分けます



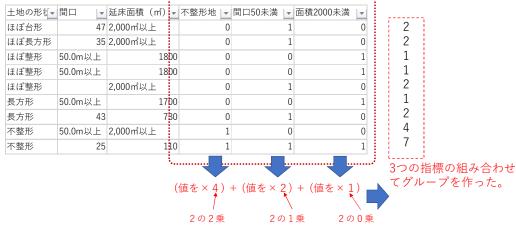


Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.

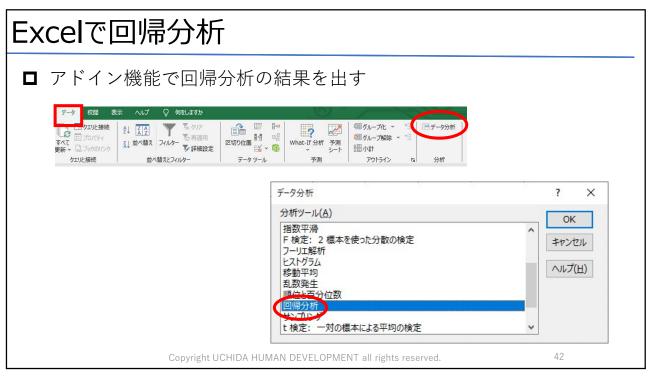
40

複数項目を1つにまとめる

■ 複数カラムの分類を1つのカラムで表現したい場合は2進数→10進数の変換のロジックを応用する



Copyright UCHIDA HUMAN DEVELOPMENT all rights reserved.





								_												
$\exists X$	(celi	C		IJ	帚	分	才	汁											
	_							_												
	٠- ١																			_
	11									自治体内部にお ける労及弥発活	2030年のあっ べき歩を設定し	※连組組の設置 等による体制づ	SDGe推進のた めに、自治体で	SDGs推進のた のに、自治体で	SDGsに関する 取組の機能発	国内外を問わな いステークホル	ローカル指標 (自治体経音の	その他SDGs 組織に向けた取		
		自治体名				===		/	SDG:について	自治体内部にお	2030年のある べき歩を設定し	経済組織の設置	SDGs核液のた のに、自分体で	SDGs前点のた のに、自治体で	SDGsに関する	国内外を関わな いステークボル	ローカル指標 (自治体独自の	その他SDGs	「地方別生 SDGs金融」に	
				目的変数		平均值	標準偏	1	推進しているか	ける普及消耗活動	た将来のビジョ	等による体制づ くり	作成している窓	作成している地	取組の情報発信、反果の井一	ダー(関係者)	評価指標)の設	担点に向けた取 組	関する取組の組	1)
	12	北海道	*	1		3	0.426401	433	4	3	3	3	合計画との記▼	万原郑音晓号》	3	との連携 7	3	3	2	北
	14	札幌市		1	2	636363636	0.542824	1347	4	3	3	2	3	2	3	2	3	2	2	16
	15	西館市		0	1	909090909	1.083306	:44	4	1	1	1	3	3	1	3	1	2	1	<u> </u>
	16	小樽市		0	2	.090909091	0.792527	081	4	2	2	1	2	3	2	2	2	2	1	#8
	17	旭川市		0	9	363636364	0.771389	216	4	2	3	2	3	3	2	2	2	2	1	85
	18	室蘭市		0	1	545454545	0.497929	598	2	2	1	1	2	2	2	2	1	1	1	<u> </u>
3		釧路市		0	2	363636364	0.979120	38 X4	4 _	3	3	3	3	3	2	2	1	1	1	1
					2															
				_	7					$\underline{\hspace{1cm}}$										
					v	′範囲			✓缶	色囲										
						甲门四			八里	ध्या										
						(Copyri	gh	t UCHID	a huma	N DEVF	LOPMEN	JT all rigi	hts reser	ved.			44		
								0''	5011101	1011/1				10001						

4	0.7820154 0.6115481 0.6086472		D	E	F	G	н	1	3	
1 模要 2 回照 4 車相開 R 5 車決定 R2 6 補正 R2 7 標準調差 8 規制数	統計 0.7820154 0.6115491 0.6086472		D	E	F	G	н	1	1	
1 模要 2 回照 4 車相開 R 5 車決定 R2 6 補正 R2 7 標準調差 8 規制数	統計 0.7820154 0.6115491 0.6086472		D	E	F	G	Н	1	3	
2 回州 4 車相開 R 5 重決定 R2 6 補正 R2 7 標準調差 8 税州数	0.7820154 0.6115481 0.6086472									
4 重相與 R 5 重決定 R2 6 補正 R2 7 標準誤至 8 稅消数	0.7820154 0.6115481 0.6086472									
4 重相與 R 5 重決定 R2 6 補正 R2 7 標準誤至 8 稅消数	0.7820154 0.6115481 0.6086472									
5 重決定 R2 6 補正 R2 7 標準調差 8 現場数	0.6115491 0.6086472									
6 補正 R2 7 標準調差 8 税消数	0.5085472									
7 標準調差 8 税消数										
8 脱洲数	0.2699342									
	1495									
9										
10 分散分析表										
11	白由反	更動		Ne れた分割						
					6E-293					
			0.0728645							
100	1484	276.30034								
lister	21.011	1011			140.000					
Total Control of the										
1000										
To the second se										
Links										
22										
170mm										
The second second										
1 Company										
1000										
1000										
28 185,7334 9	0.2000421	0.0147472	13.554758	1.300E-39						
	19 自治体内部 20 2030年のま 21 推進組織の 22 SDG:推進 23 SDG:推進 24 SDG:に開 25 国内外を再 26 ローカル根	13 発差 1473 14 白計 1484 15 18	13	13 無差 1473 107.3094 0.705048 14 会計 1444 778.30034 15	13 報報 1477 107.3094 0.0709688 14 14 15 17 107.3094 0.0709688 15 15 15 17 17 17 17 18 17 18 17 18 17 17 17 17 18 18 18 18 18 18 18 18 18 18 18 18 18	13 元年 1473 107-3294 0.0729845 148 147 1484 178 30034 148 148 178 30034	13 無常 1473 107.3294 0.072845 12 12 12 12 12 12 12 12 12 12 12 12 12	13	13 변부 1475 107.3204 0.0708645	1월 설치 14대